Magíster en Data Science - Big Data y Cloud Computing

Gestión Territorial Inteligente

Arquitectura Big Data para Solicitudes Ciudadanas en la Municipalidad de El Monte

Diseño, Implementación y Análisis Técnico (Fases 1 a 3) | **Grupo 2** (Alanís, Neira, Sandoval, Aguirre)

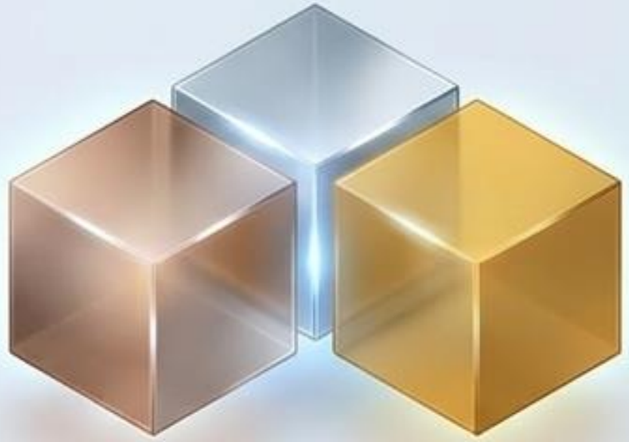
NotebookLM


Ingreso
Validación
Asignación
Visita Terreno
Fotografía
Cierre
Encuesta Satisfacción
Solicitud Ciudadana
Fragmentación Estructural
Datos aislados entre DIMAO, Seguridad Pública y DIDECO. Sin visión única.
Ceguera Territorial
Carencia de georreferenciación centralizada para priorización inteligente.
SLA Ocultos
Imposibilidad actual de medir el desempeño real de cuadrillas y cuellos de botella operativos.
El desafío no es recibir la solicitud, es gobernar su ciclo de vida territorial completo con trazabilidad absoluta.

NotebookLM



Fuentes Heterogéneas



Motor Lakehouse



Impacto de Negocio

Patrón Analítico

Lakehouse Medallion (procesamiento Batch incremental).

Procesamiento Core

PySpark distribuido (escala real y paralelismo).

Almacenamiento

Formato columnar Parquet (compresión Snappy para I/O eficiente).

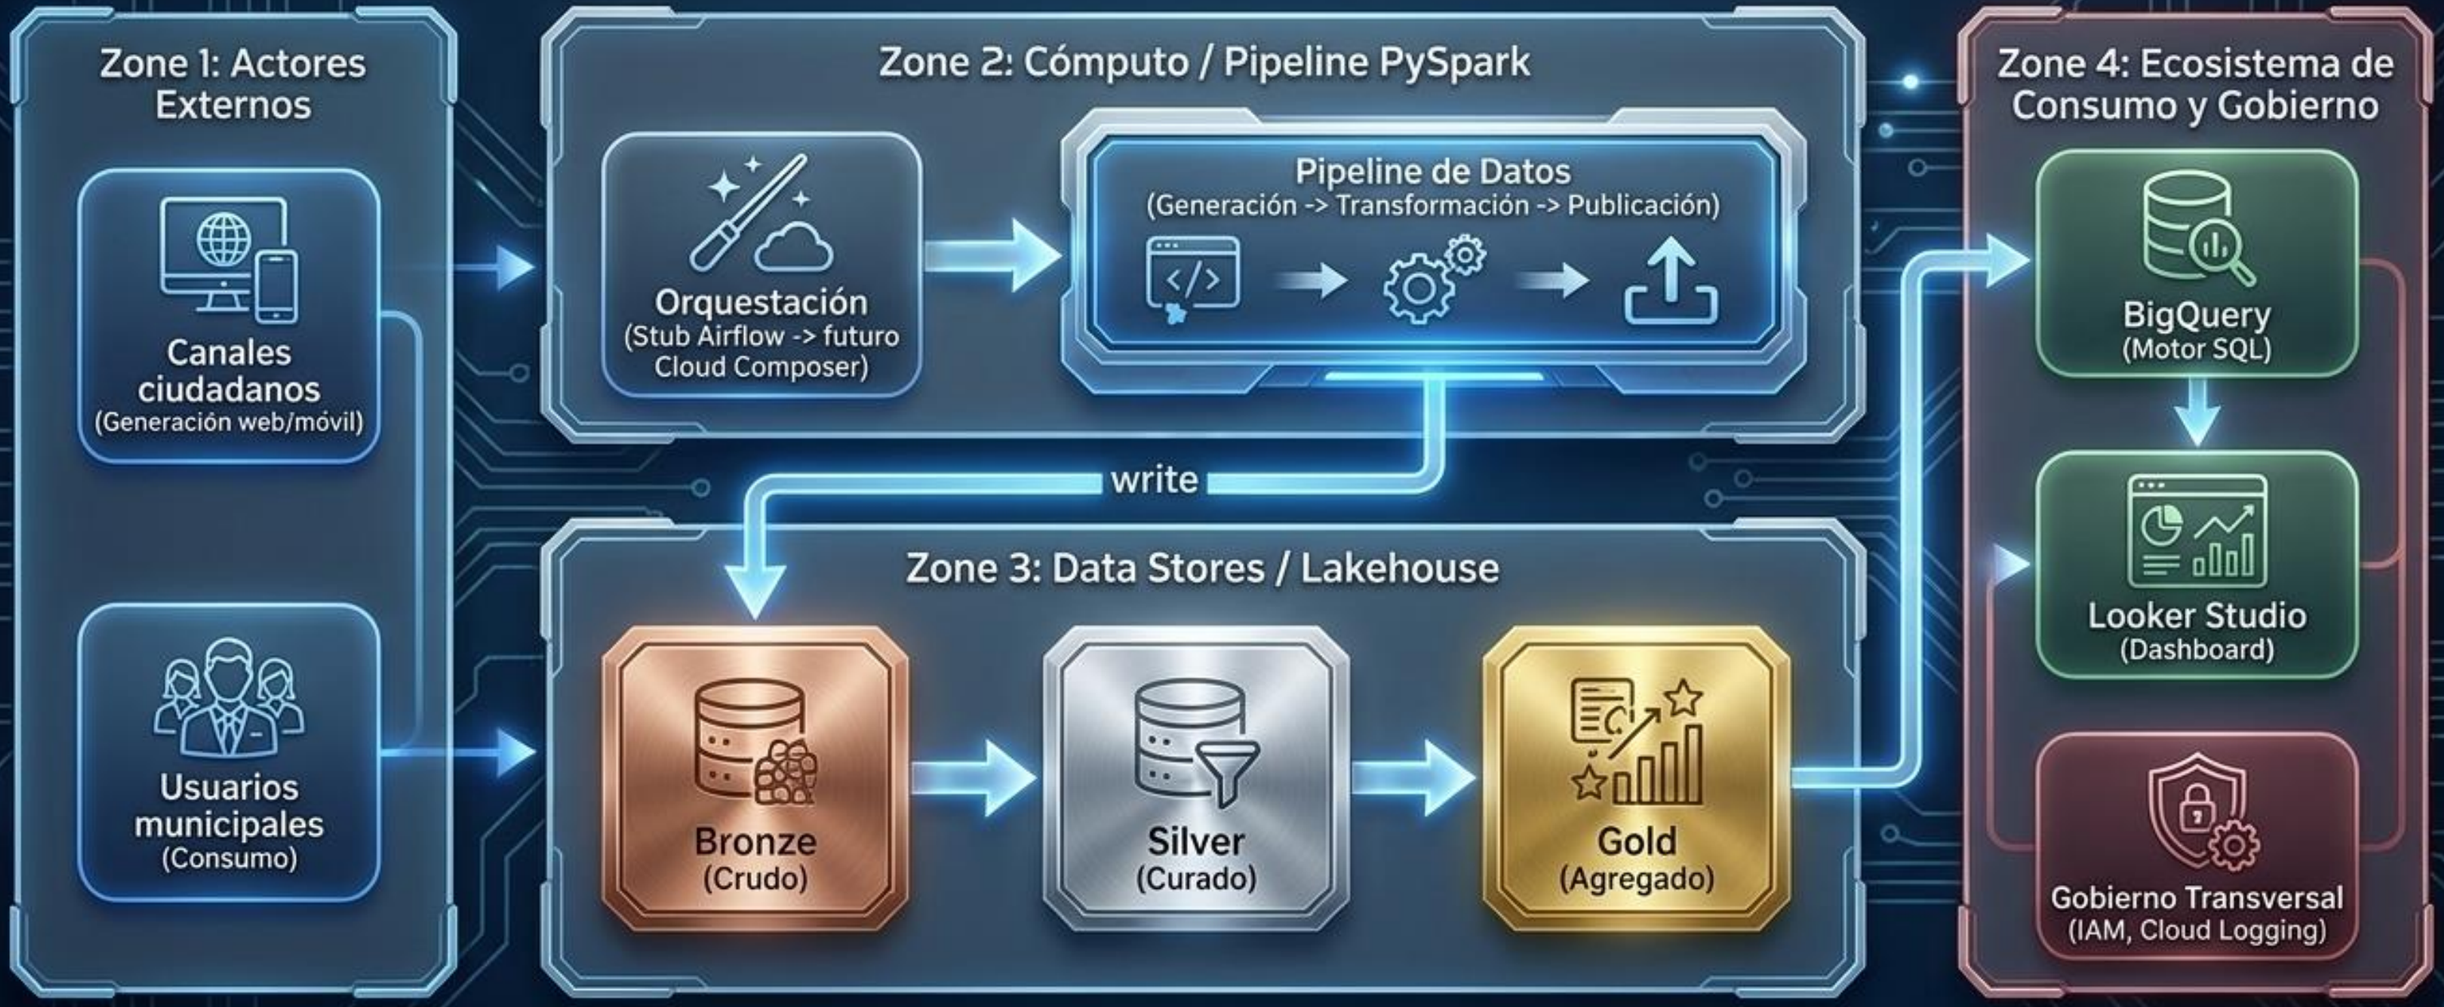
Estrategia de Escalamiento

Diseño inicial local estrictamente reproducible, preparado arquitectónicamente para despliegue nativo en GCP.

NotebookLM

C4 Nivel 2 - Contenedores principales

Gestión Territorial Inteligente - Arquitectura de Procesamiento y Almacenamiento



Insight: Arquitectura desacoplada. El almacenamiento (Parquet) opera independientemente del motor de cómputo (PySpark), permitiendo escalar costos y rendimiento por separado.

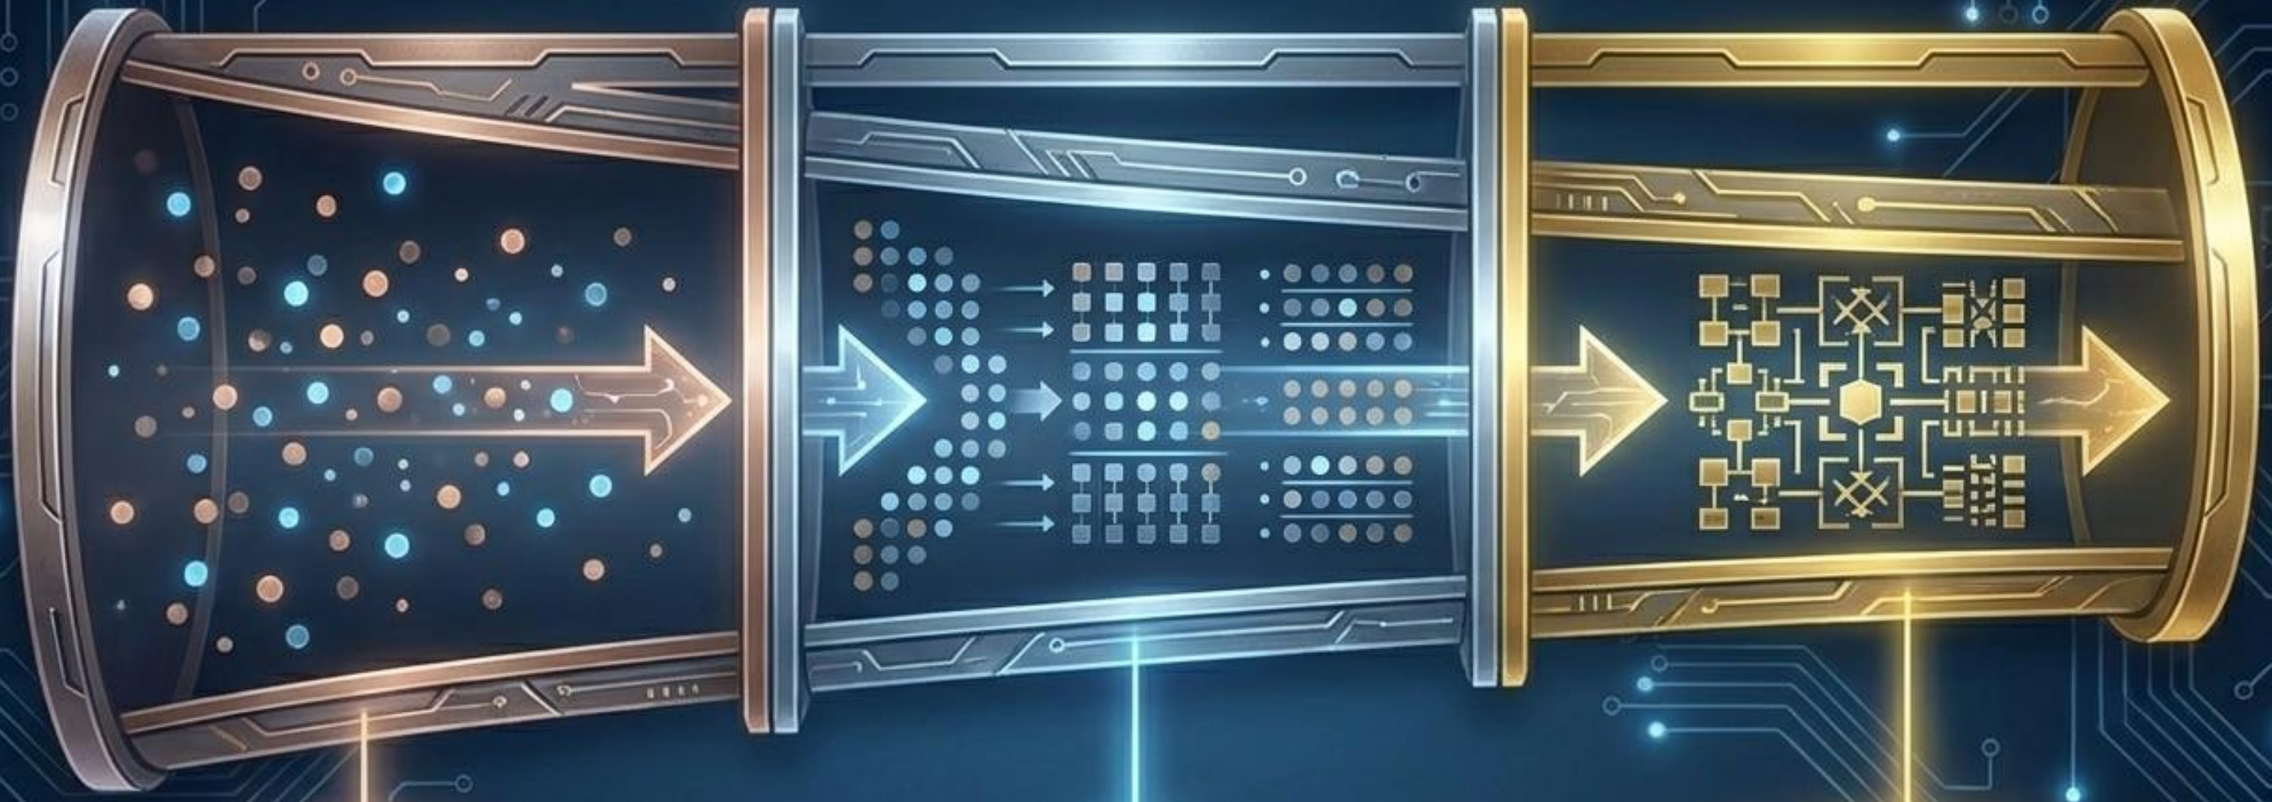
NotebookLM



Small (Validación local)	**Medium** (Prueba intermedia)	**Full** (Escala Big Data real)
5K Solicitudes	**50K** Solicitudes	**50K** Solicitudes
120K Eventos	**2M** Eventos	**10.8M** Eventos
35K Logs	**500K** Logs	**1.5M** Logs

Diseño de Datos Sintéticos: No simulamos filas aisladas; simulamos 8 años de historias operacionales completas. Se protegió la privacidad ciudadana mediante hashes criptográficos (SHA-256), forzando al motor a procesar más de 12 millones de registros base sin comprometer datos sensibles.

NotebookLM



BRONZE (Crudo)

Estado: Persistencia inmutable. Formato Parquet raw.

Propósito: Trazabilidad técnica, auditoría y capacidad de reprocesamiento total sin depender de la fuente.

SILVER (Curado)

Estado: Normalización, limpieza y joins espaciales/climáticos.

Propósito: Deduplicación y cálculo de flags operacionales críticos (es_vencida, es_critica, tiene_reapertura). La verdad única confiable.

GOLD (Analítico)

Estado: Agregación orientada al modelo de negocio.

Propósito: Tablas de consumo directo (KPIs SLA, Backlog, Zonas Críticas). Consumo inmediato en dashboards sin necesidad de joins costosos.

NotebookLM

Métricas de Volumen: Registros Bronze



Métricas de Volumen: Registros Silver



12,429,220
Registros totales procesados en capa Bronze

41.65 Minutos
Tiempo total de ejecución interactiva (execution_status=success)

0%
IDs críticos nulos en Silver tras validación

0%
Coordenadas fuera de rango territorial

Conclusión Operacional: El pipeline procesó de manera estable y exitosa 8 años de historia sintética en un entorno local restringido, demostrando eficiencia algorítmica y sentando una base sólida para la migración a servicios cloud administrados.

NotebookLM

Benchmark: Parquet Base vs Parquet Optimizado (Particionado)



Análisis Crítico (Honestidad Técnica - ADR-004)

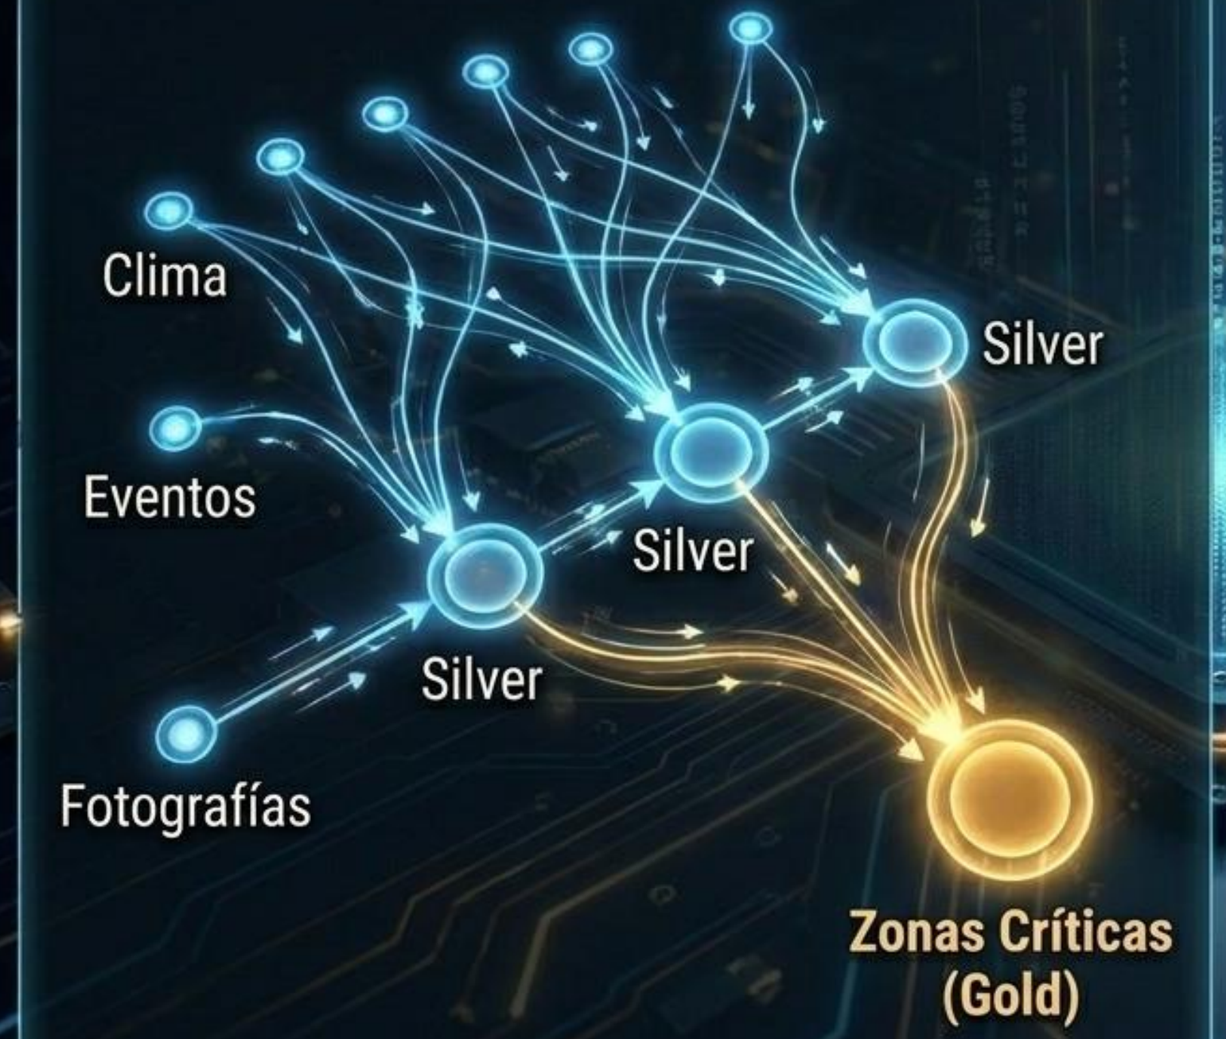
El Mito: Particionar siempre mejora la velocidad de lectura.

La Realidad (Escala Full): Con 10.8M de eventos, usar 4 llaves (año, mes, zona_gestion, tipo_evento) empeoró el rendimiento en un 41.98%.

La Lección: El costo de listar e inspeccionar miles de archivos pequeños (small files problem) superó ampliamente el beneficio del partition pruning. La solución en GCP requerirá afinar la granularidad o aplicar clustering/Z-order.

NotebookLM

Data Lineage Network



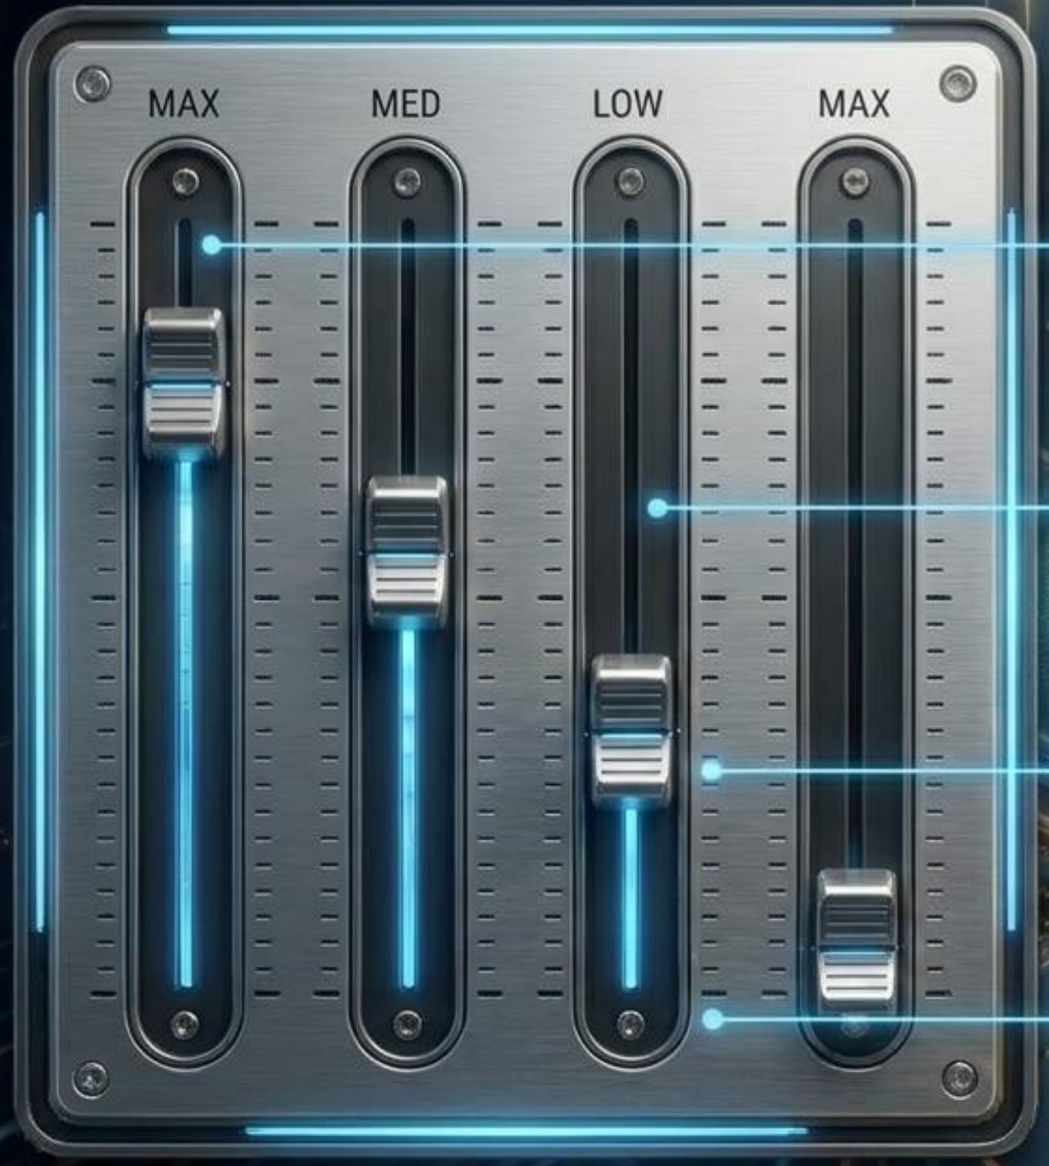
"En la gestión pública, la trazabilidad no es un lujo técnico, es una condición de legitimidad institucional."

Matriz de Accesos (RBAC)

	Rol	Permisos y Alcance
1	Administrador Técnico	Acceso total (Bronze / Silver / Gold)
2	Analista de Datos	Exploración y modelos (Silver / Gold)
3	Autoridad Municipal	Toma de decisiones (Solo Dashboards sobre Gold)
4	Operador de Cuadrilla	Vista filtrada de solicitudes asignadas

NotebookLM

Control de Costos Implementado (FinOps Lever System)



Separación Cómputo/Almacenamiento

Dataproc Serverless (se enciende solo al procesar) vs. Cloud Storage (almacenamiento pasivo económico).

Estrategia de Materialización (Gold)

Looker Studio ataca tablas Gold agregadas minúsculas (ej. 24 filas de kpi_sla), bloqueando consultas directas a los 12M de registros en Bronze.

Gestión de Ciclo de Vida

Políticas de retención en GCS para enviar históricos de Bronze a almacenamiento Coldline/Archive.

Modelo de Ejecución

Batch incremental periódico (Costo-eficiente) vs. Streaming continuo (Innecesario para SLA de 48 hrs).

NotebookLM

Presión Territorial



Cumplimiento SLA (DIMAO, Seguridad, Salud)



Backlog Operacional Histórico



Principio Core: Las autoridades no navegan por la bodega (Bronze/Silver); consumen directamente en el mostrador (Gold). Todo el esfuerzo de ingeniería Big Data tiene como único fin sustentar esta vista con datos veraces y trazables.

NotebookLM

Prevención de Data Leakage
(Fuga de Información)



- **Regla de Negocio:** Para entrenar un modelo predictivo de criticidad, el dataset Gold se construyó utilizando exclusivamente variables disponibles en el minuto cero (T0).
- **Objetivo Futuro:** Asignar criticidad automática con IA (Human-in-the-loop), validada por supervisores municipales.

NotebookLM

La Ruta de Evolución a Producción GCP



NotebookLM

ADR-001: Lakehouse Medallion



Decisión: Implementar capas lógicas Bronze, Silver y Gold.

Impacto: Garantiza el reprocesamiento seguro sin pérdida de datos crudos y permite una calidad de datos escalonada.

ADR-002: PySpark + Parquet



Decisión: Utilizar el estándar de industria para Big Data.

Impacto: Habilita compresión eficiente (Snappy) y procesamiento distribuido real, superando las limitaciones de memoria de herramientas locales como pandas.

ADR-003: Ejecución Full Rigurosa



Decisión: Procesar la escala máxima (>12M eventos) sin recortes.

Impacto: Demuestra la viabilidad real del diseño técnico antes de invertir presupuesto municipal en la nube.

ADR-004: Honestidad en Benchmark



Decisión: Reportar el empeoramiento del rendimiento al particionar.

Impacto: Valida el criterio técnico real frente a dogmas teóricos, aceptando los límites físicos de listar miles de archivos pequeños.

NotebookLM


La infraestructura Big Data no es solo un habilitador técnico; es el motor de modernización del Estado. Este proyecto demuestra que es posible transformar el caos de eventos territoriales dispersos en un Pipeline de Cristal: evidencia trazable, gobernable y transparente para la toma de decisiones en la Municipalidad de El Monte.
Arquitectura validada. Lista para despliegue productivo en GCP.
NotebookLM